Rapport de projets : Deep Learning et Data

Classification d'Images & de Textes

Cyrian Revel–Hidalgo

27 octobre 2026

Plan de la présentation

1. Partie 1 : Classification d'images Satellites
2. Partie 2 : Classification de Textes

1. Contexte et Données

Objectif : Détecter la présence d'éoliennes sur des images satellites (Classification binaire : Target / Other).

Le jeu de données :

- Images couleurs, taille 128 x 128.
- Entraînement : 58 218 images (dont 20% isolés pour un test interne).
- Validation et Test final : 5 000 images chacun.

Contraintes matérielles :

- Machine locale avec GPU GTX 1070.
- Obligation d'utiliser TensorFlow 2.10 pour la compatibilité CUDA (accélération GPU).

1. Modèles de base et CNN Profond

Modèles de base :

- **Régression logistique** : 49 000 paramètres. Rapide, précision $\approx 85\%$.
- **CNN Simple** : 1 couche de convolution + MaxPooling + Dense. Précision $\approx 94\%$.

CNN Profond :

- Couches de convolution successives ($32 \rightarrow 64 \rightarrow 128$), MaxPooling et Dropout.
- 560 000 paramètres, entraînement en 9 epochs (Early Stopping).
- **Précision :** 96,86% (Validation) | 97,28% (Test interne).

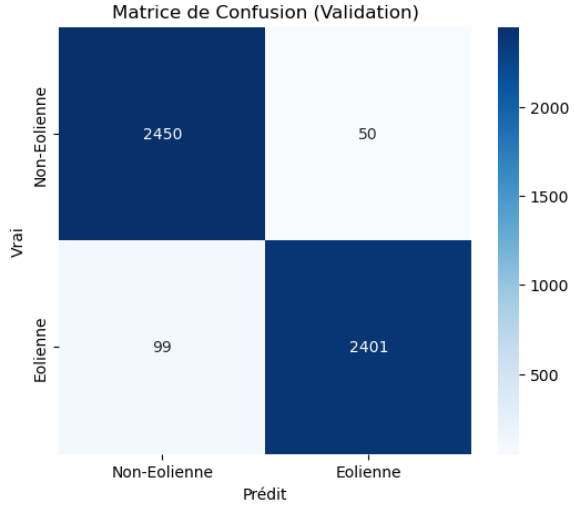
Essais annexes (Data augmentation, filtres 3x3) : Peu d'impact sur la précision ou entraînement trop ralenti.

1. Transfer Learning et Fine-Tuning

Utilisation de modèles pré-entraînés par Google (réentraînement des dernières couches) :

- **EfficientNetB0** : Précision de 97,38%.
- **EfficientNetV2 Small** : Modèle lourd (20M de paramètres), précision de 97,20%.
- **MobileNetV3** : Très léger (3M de paramètres, conçu pour mobile), précision de **97,43%**.

Matrice de confusion EfficientNet B0



1. Synthèse des performances (Images)

Modèle	Paramètres	Précision (Val)	Précision (Test Int.)	Temps / Ép.
Logistique	49 000	85,84%	85,87%	15s
CNN Simple	7 900 000	93,34%	94,10%	25s
CNN Profond	560 000	96,86%	97,28%	75s
EfficientNetV2 S	20 000 000	96,80%	97,20%	150s
MobileNetV3	**3 000 000**	**97,18%**	**97,43%**	**70s**

Le modèle MobileNetV3 offre le meilleur compromis entre légèreté et précision.

1. Bilan de la détection d'éoliennes

Analyse de la généralisation sur le jeu de test final :

- Malgré des scores de $\approx 97\%$ en validation, les modèles **stagnent à 90%** sur le vrai jeu de test.

Causes probables :

- Différence de distribution (les images test proviennent potentiellement de zones géographiques ou de lots différents).
- Erreurs d'étiquetage ou éoliennes quasi-imperceptibles à l'œil nu.

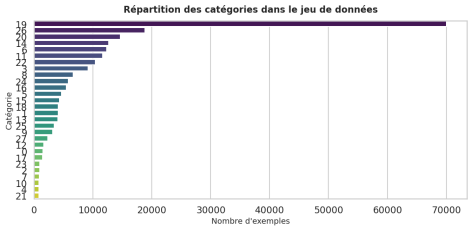


2. Contexte et Jeu de données NLP

Objectif : Prédire une catégorie de métier (parmi 28 possibles) à partir d'une description de poste en anglais.

Données brutes :

- Issues de CommonCrawl (web).
- Plus de 200 000 textes disponibles (réduits pour correspondre aux capacités matérielles).
- **Problème majeur :** Fort déséquilibre entre les classes (la classe de professeur est sur-représentée).



2. Prétraitement et Méthodologie

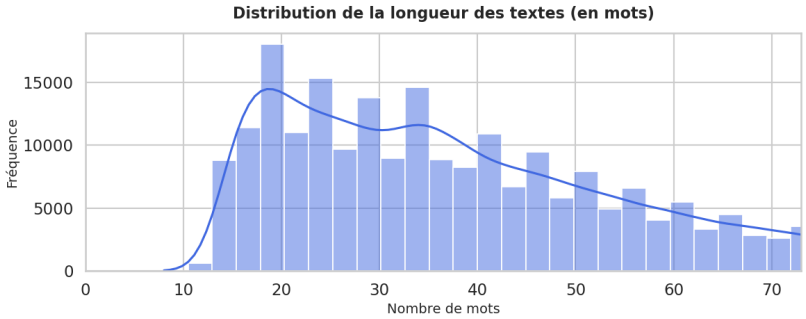
Nettoyage des textes :

- Passage en minuscules, suppression ponctuation/caractères spéciaux.
- Filtrage des *stop words* et **lemmatisation**.
- Résultat : majorité des textes entre 15 et 50 mots.

Stratégie d'évaluation :

- Utilisation de la **Validation croisée (5 folds)** : S'assurer que le modèle est robuste peu importe l'échantillonnage.
- Étude des **matrices de confusion** : L'accuracy globale est trompeuse avec un jeu déséquilibré, il faut vérifier les classes minoritaires.

Répartition de la longueur des textes



2. Modèles de référence (Naïfs Bayésiens)

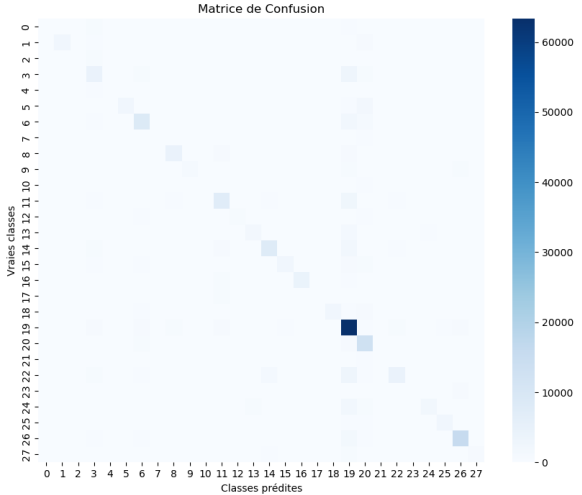
Bag of Words (BOW) vs TF-IDF (Vocabulaire limité à 10 000 mots) :

- **BOW** : 71,13% de précision globale.
- **TF-IDF** : 69,76% de précision globale.

Analyse des erreurs :

- Les classes rares (ex : 7, 10, 21) sont excellemment prédites ($> 99\%$) car leur vocabulaire est très spécifique.
- Les classes ultra-fréquentes (ex : 3) ne sont qu'à 40% car leur vocabulaire recoupe beaucoup d'autres métiers.

Matrice de confusion Bow



2. Réseaux de Neurones Denses

Problème : Les matrices creuses (10 000 colonnes) sont impossibles à traiter en l'état pour un réseau dense.

Solution : SVD (Singular Value Decomposition)

- Réduction de la dimensionnalité à des vecteurs denses de taille 300.
- Modèle à 100 000 paramètres : très rapide ($\approx 10s$/epoch).

Performances :

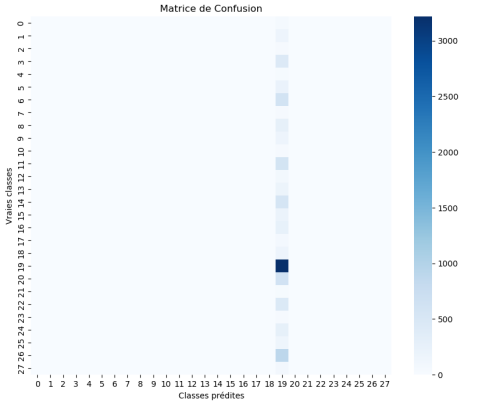
- BOW + SVD + Dense : 76,00%
- **TF-IDF + SVD + Dense : 77,29%** (Meilleur score actuel).

2. L'échec du modèle séquentiel (LSTM)

Tentative avec une architecture adaptée au texte (Embedding + LSTM 64 unités + Padding).

Résultat : Chute à 32,25% de précision.

Pourquoi ?
Le réseau "abandonne" et choisit la solution de facilité : il ne prédit **plus que la classe professeur** (qui représente 1/3 du dataset).



2. La solution : Gestion des Poids de Classes

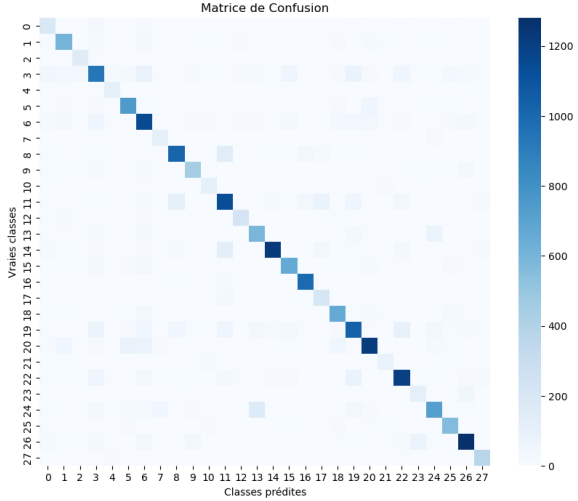
Concept : Pénaliser fortement le modèle s'il se trompe sur une classe rare, et faiblement sur une classe fréquente.

Impact sur les modèles :

- Peu d'impact sur le Bayésien ou le réseau Dense.
- **Sauvetage du LSTM** : Le modèle se débloque.
- LSTM (Embeddings aléatoires) $\rightarrow$ **76,27%**
- LSTM (Word2Vec) $\rightarrow$ **74,45%**

Cependant, le temps d'entraînement du LSTM est beaucoup plus long (30s/epoch sur 15 epochs).

Matrice de confusion LSTM



Bilan NLP : Tableau Récapitulatif

Modèle	Paramètres	Précision	Poids	Epochs	Temps / epoch
BOW Bayésien	280 000	71,13%	Non	5	3s
TF-IDF Bayésien	280 000	69,76%	Non	5	3s
BOW Dense	100 000	76,00%	Non	5	10s
TF-IDF Dense	**100 000**	**77,29%**	**Non**	**5**	**10s**
LSTM Aléatoire	1 000 000	76,27%	Oui	15	30s
LSTM Word2Vec	1 000 000	74,45%	Oui	15	30s

Conclusion : L'approche classique (TF-IDF + SVD + Réseau dense) offre le meilleur compromis précision / temps de calcul sur nos machines.

Conclusion Générale et Perspectives

Le plafond de verre ($\approx 77\%$)

- Recoupement de vocabulaire : Certains métiers sont très proches textuellement (ex : *Software Engineer* vs *Data Scientist*).
- Le nettoyage agressif fait perdre certaines nuances de contexte de la phrase.

Pistes d'amélioration :

- Passer à l'architecture **Transformers** (ex : BERT).
- Avantage : L'attention bidirectionnelle permet de mieux comprendre le sens complet de la phrase.
- Limite actuelle : Nécessiterait des ressources matérielles.

Merci de votre attention !

Avez-vous des questions ?